網路爬蟲基本篇

基本流程

1.找到要爬的網站取得他的網址

2.解析他的資料，取得你想要的部分

抓取資料

最重要的是要讓程式執行假裝自己是人

所以要讓網站覺得程式是一般使用者

為甚麼

1. 伺服器負載與穩定性問題 EX.DDos
2. 資料是他們的資產（商業利益）
3. 隱私與法律責任



The True Cost of a DDoS Attack

Understand the extensive impact of DDoS attacks, from revenue loss to legal and regulatory issues, beyond just downtime.

Corero Network Security / Aug 27, 2025

HTML格式

```
<html>
    <head>
        <title>HTML </title>
    </head>
    <body>
        <div class ="list">
            <span>階層結構</span>
        </div>
    </body>
</html>
```

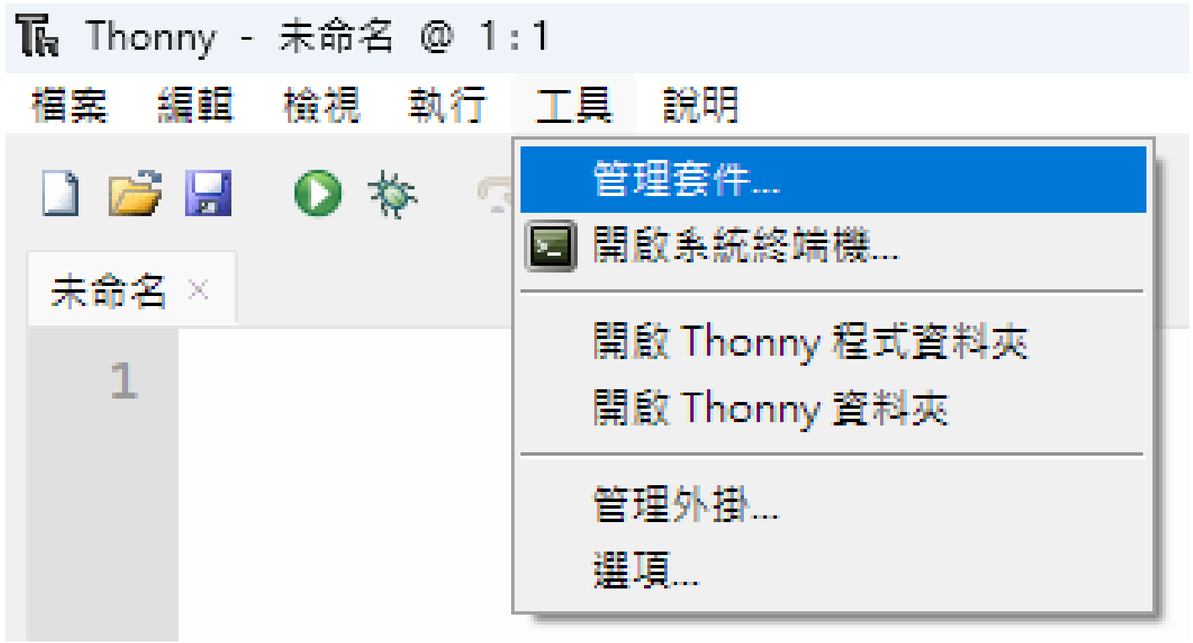
解析html格式

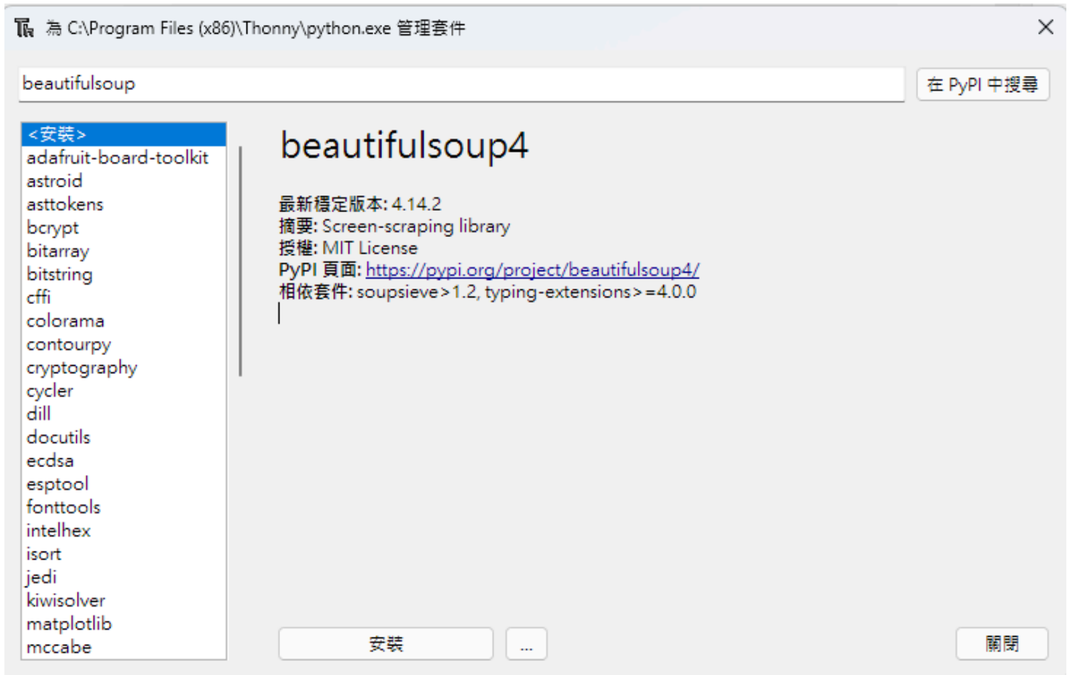
我們可以使用第三方套件

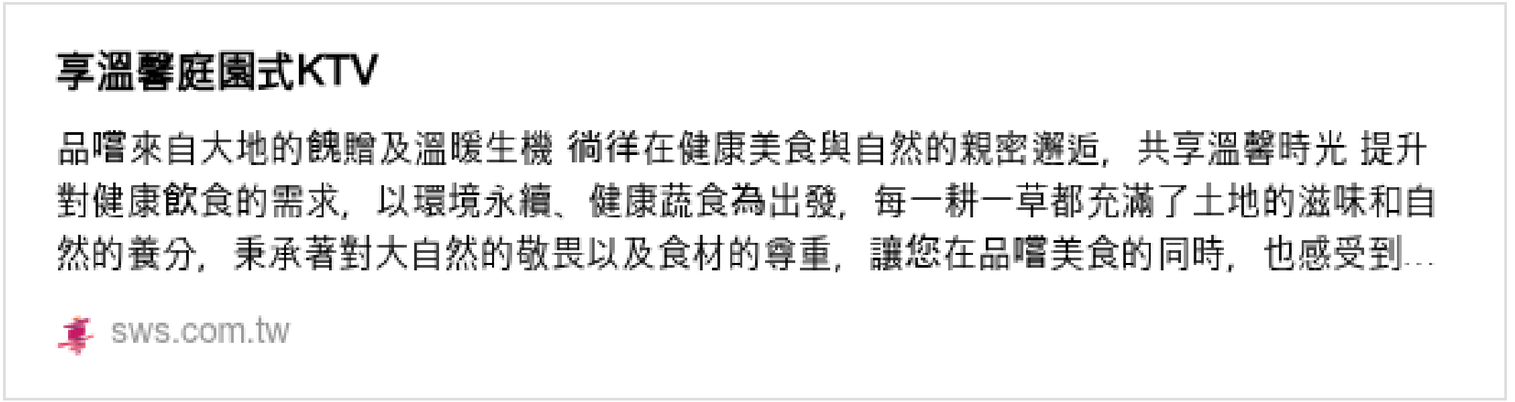
beautifulsoup來做解析

安裝套件

我們使用thonny 自帶函式庫安裝套件
beautifulsoup4







https://tixcraft.com/activity

```
#加入header看起來像人類
request=req.Request(url, headers={
   "User-Agent":"你的電腦的資料"  })
```

解析資料

beautifulsoup4

```
import bs4
root=bs4.BeautifulSoup(data,"html.parser")
```

```
#抓取網頁原始碼
import urllib.request as req

url="https://www.sws.com.tw/song.html?q=sort"
request=req.Request(url)
with req.urlopen(url) as response:
    data=response.read().decode("utf-8")
import bs4
root=bs4.BeautifulSoup(data,"html.parser")
```

```
#抓取網頁原始碼
import urllib.request as req

url="https://www.sws.com.tw/song.html?q=sort"
request=req.Request(url)
with req.urlopen(url) as response:
    data=response.read().decode("utf-8")
import bs4
root=bs4.BeautifulSoup(data,"html.parser")
print(root.title.string)
songs = root.find_all("div",class_="song")
#print(songs)
#如果我想要編號 我應該要怎麼寫
for s in songs:
    songnames_div= s.find('div',class_="song-name")
    singers_div=s.find('div',class_="singer")

    songnames=songnames_div.p.string
    singers=singers_div.p.string

    print(songnames)
    print(singers)
    print("-------")
```

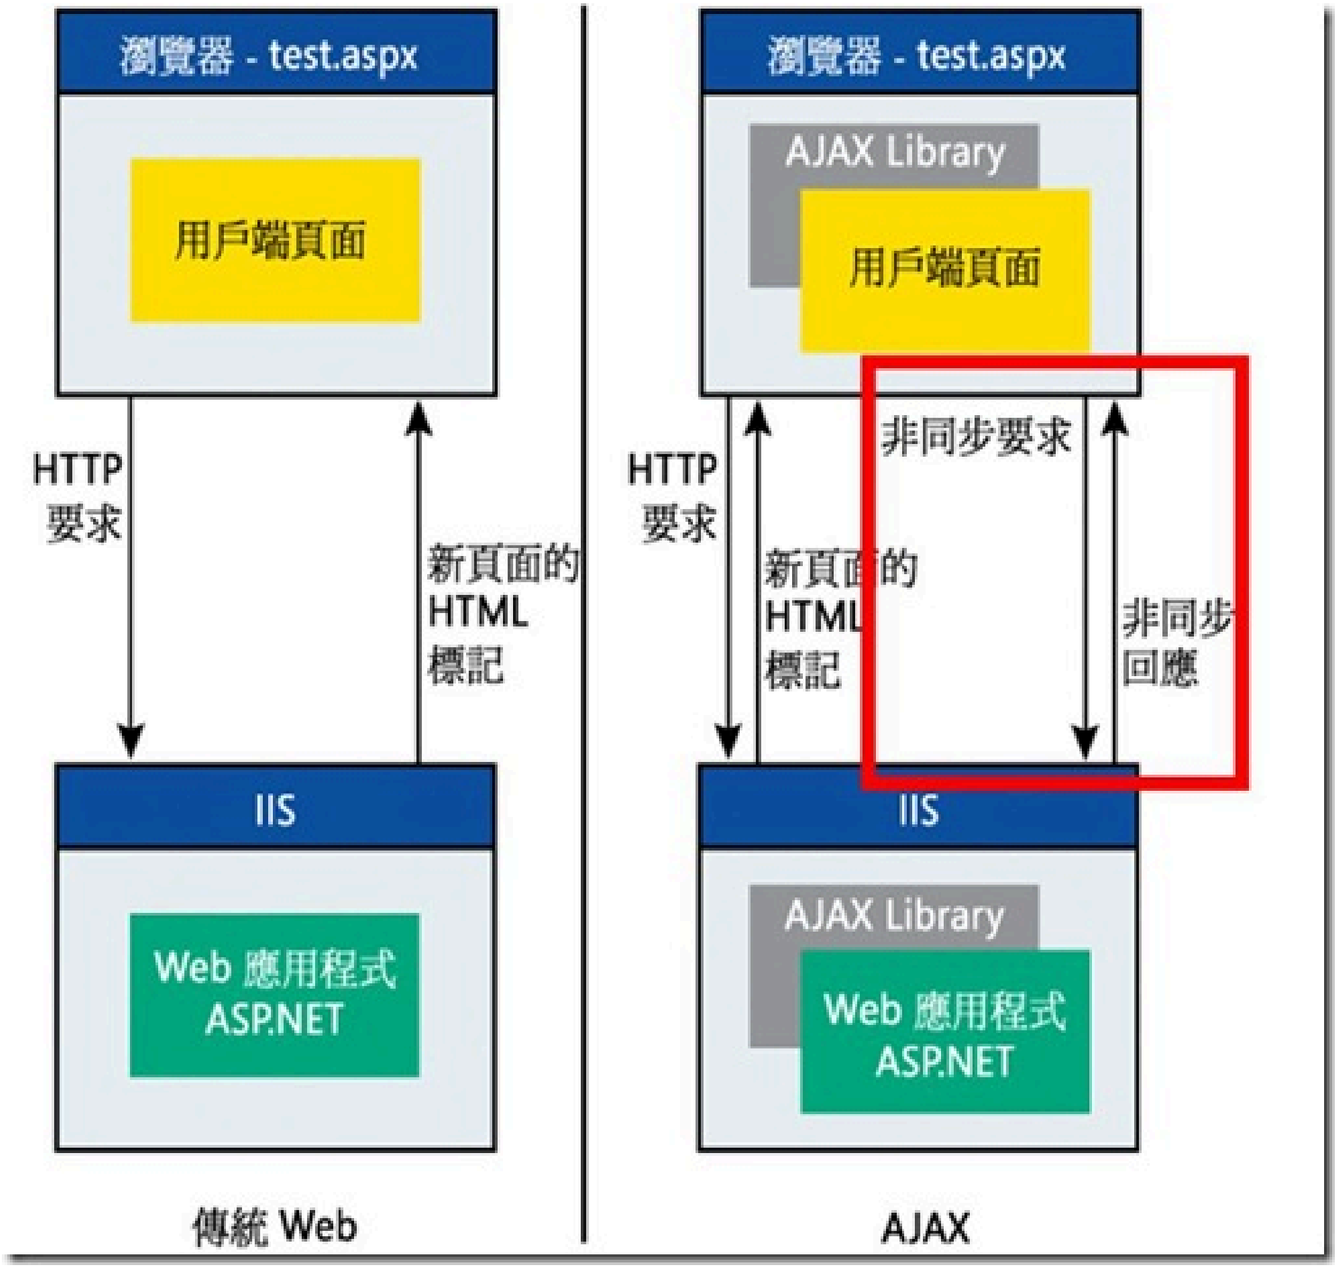
Python 網路爬蟲教學
AJAX / XHR 網站技術分析

基本流程

1.找到要爬的網站取得他的網址

2.解析他的資料，取得你想要的部分

甚麼是AJAX
網頁前端JAVA SCRIPT的技術


瀏覽器 - test.aspx
用戶端頁面
HTTP
要求
新頁面的
HTML
標記
IIS
Web 應用程式
ASP.NET
傳統 Web
瀏覽器 - test.aspx
AJAX Library
用戶端頁面
HTTP
要求
非同步要求
新頁面的
HTML
標記
非同步
回應
IIS
AJAX Library
Web 應用程式
ASP.NET
AJAX

誠品書店

https://www.eslite.com/best-sellers/online/3?type=0

享溫馨庭園式KTV

sws.com.tw

```
import urllib.request as req
import json
url = "  "
headers = {"User-Agent": "Mozilla/5.0"}
request = req.Request(url, headers=headers)
with req.urlopen(request) as response:
    data = response.read().decode("utf-8")
    json_data = json.loads(data)#將json 解析成字典跟列表的表示形式
print(type(json_data))
```

```
import urllib.request as req
import json

url = "https://athena.eslite.com/api/v1/best_sellers/online/day?l1=3&page=1&per_page=20"
headers = {"User-Agent": "Mozilla/5.0"}

request = req.Request(url, headers=headers)
with req.urlopen(request) as response:
    data = response.read().decode("utf-8")
    json_data = json.loads(data)#將json 解析成字典跟列表的表示形式

#print(type(json_data))
num=0
for product in json_data["products"]:
    num+=1
    print("第"+str(num)+"名")
    print(product["name"],end=" 作者:")
    print(product["author"])
```

```
import urllib.request as req
import json

url =
"https://athena.eslite.com/api/v2/products/10012030542683019858008,1001191562686239,10011915626823214180
09,1001253972868718,10012011762683030341008,10012010632683032464002,1001112702764163,10012119292682459138008,10012013192682923918006,10012014082682978296005,10012030392682827161003,1001202005268300267100
3,1001110932661544,10012894026823000390
03,10012030392683021064008,10012168942682952409001,10012020052683003866002,10012010632683018708007,10012011762682390691006,10012010042683029454009/prices"

headers = {"User-Agent": "Mozilla/5.0"}

request = req.Request(url, headers=headers)
with req.urlopen(request) as response:
    data = response.read().decode("utf-8")
    json_data = json.loads(data)#將json 解析成字典跟

#print(type(json_data))
for product in json_data:
```

互動環境

```
特價：  331
納瓦爾寶典：從白手起家到財務自由，矽谷傳奇創投家的投資哲學與人生智慧 (附限
原價：  450
特價：  355
刺蝟抱月亮 (附首刷限定自癒系吉籤)
原價：  450
特價：  355
易學易用黃帝內經：中醫師反覆研讀的寶典，如今一般人也能實踐 12條經絡、365
原價：  499
特價：  394
我教的不只是棒球，還有人生競爭力
原價：  550
特價：  434
大人只知道部分的世界：寫給年輕的你
原價：  350
特價：  350
```

Python Selenium

快速開始 網頁截圖

Selenium是什麼

一個瀏覽器自動化的套件

Selenium 的用途

快速截圖　網頁爬蟲 自動化測試

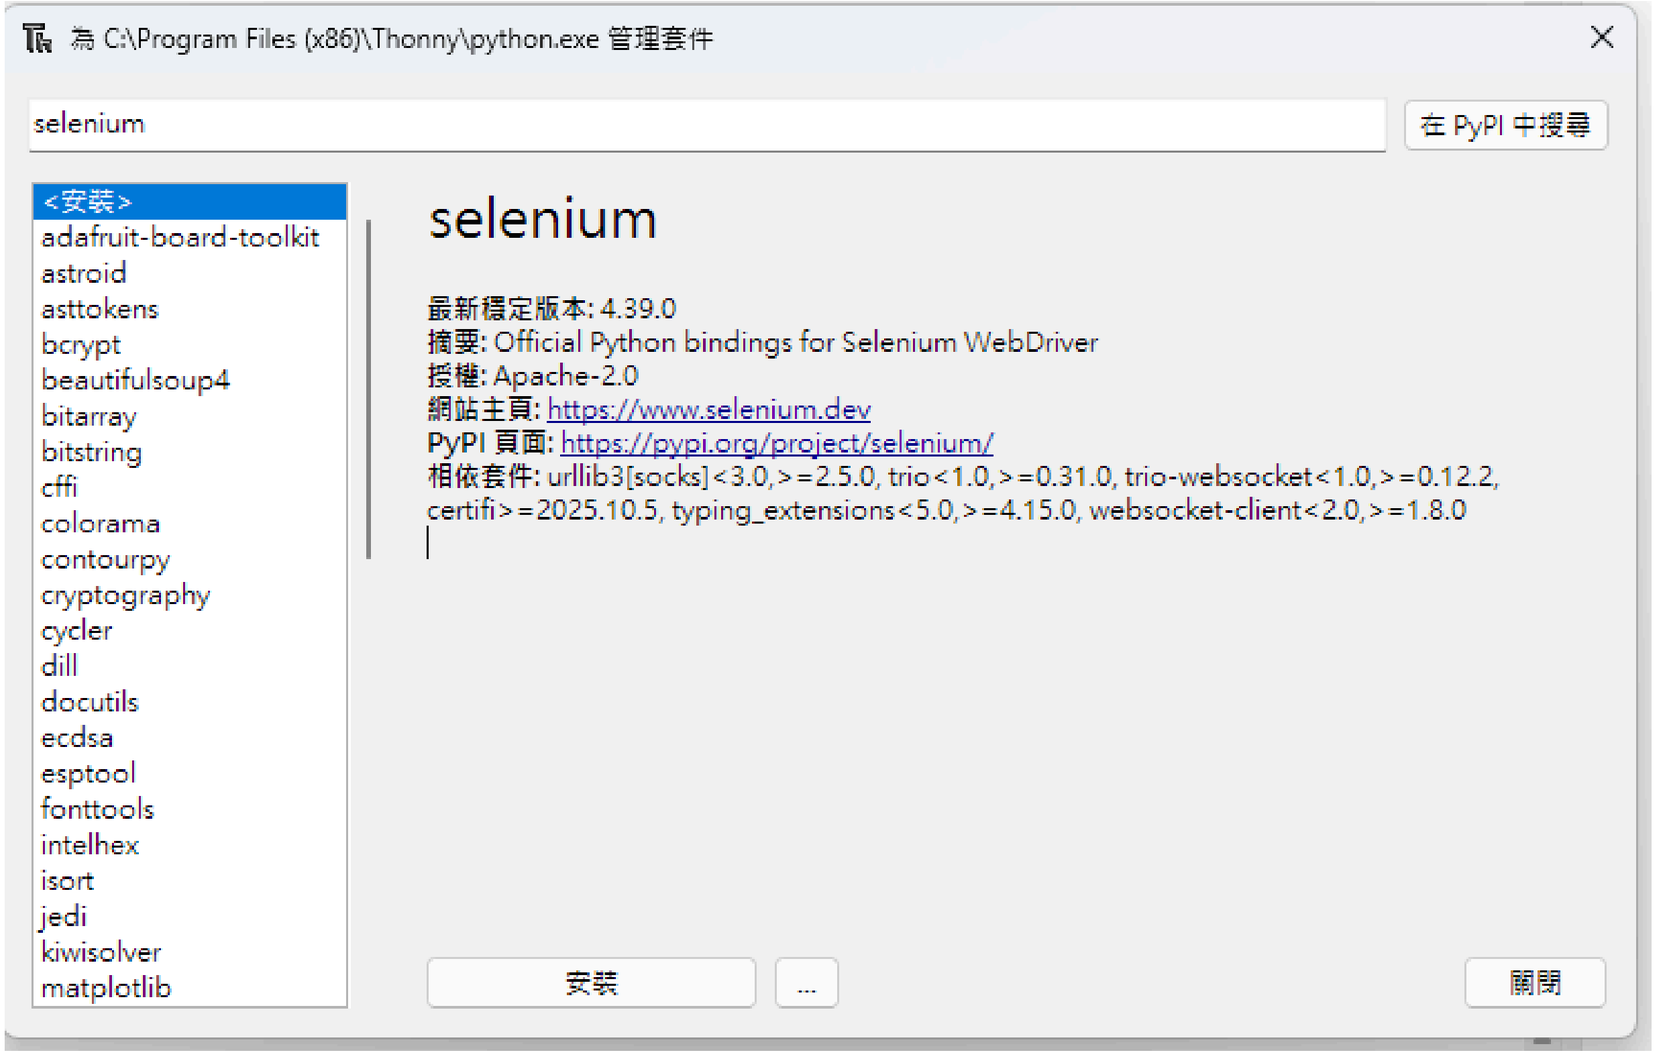
要做的事

1. 去chrome driver 下載驅動程式
2. 下載**Selenium**
3. 嘗試使用網頁截圖

Chrome driver

google 搜尋chrome driver驅動

安裝Selenium


為 C:\Program Files (x86)\Thonny\python.exe 管理套件
selenium
在 PyPI 中搜尋
<安裝>
adafruit-board-toolkit
astroid
asttokens
bcrypt
beautifulsoup4
bitarray
bitstring
cffi
colorama
contourpy
cryptography
cycler
dill
docutils
ecdsa
esptool
fonttools
intelhex
isort
jedi
kiwisolver
matplotlib
selenium
最新穩定版本: 4.39.0
摘要: Official Python bindings for Selenium WebDriver
授權: Apache-2.0
網站主頁: https://www.selenium.dev
PyPI 頁面: https://pypi.org/project/selenium/
相依套件: urllib3[socks]<3.0,>=2.5.0, trio<1.0,>=0.31.0, trio-websocket<1.0,>=0.12.2, certifi>=2025.10.5, typing_extensions<5.0,>=4.15.0, websocket-client<2.0,>=1.8.0
安裝
...
關閉

連接chrome

```
#載入相關模組
from selenium import webdriver
from selenium.webdriver.chrome.options import Options
#設定Chrome driver執行檔案
options = Options()
options.chrome_executable_path="你下載的位置"
driver = webdriver.Chrome()
driver.get("https://www.google.com/")
driver.close()
```

用selenium截圖

```
driver.get("https://www.mksh.phc.edu.tw/")
driver.save_screenshot("C:/Users/Downloads/mksh.png")


driver.maximize_window()
```

```
#載入相關模組
from selenium import webdriver
from selenium.webdriver.chrome.options import Options

from selenium.webdriver.common.by import By # 專門用來指定元素查找方式
from selenium.webdriver.common.keys import Keys # 模擬鍵盤操作
import time
#設定Chrome driver執行檔案
options = Options()
options.chrome_executable_path="你下載的位置"

#建立driver實體 用程式來操作瀏覽器
driver = webdriver.Chrome(options=options)
driver.maximize_window()
driver.get("https://www.mksh.phc.edu.tw/")

# 找到搜尋框 (使用 ID)
search_box = driver.find_element(By.ID, "ocean-search-form-11")
# 在搜尋框輸入文字
search_box.send_keys("午餐菜單")
# 模擬按下 Enter 鍵來送出搜尋
search_box.send_keys(Keys.ENTER)
time.sleep(2)
first_result_link = driver.find_element(By.CSS_SELECTOR, "h2.entry-title a")
first_result_link.click()
time.sleep(2)
# 找到下載按鈕
download_button = driver.find_element(By.CSS_SELECTOR, "a.wp-block-file__button")
download_button.click()
time.sleep(2)
driver.close()
```